

Clase 2

Tema 2: Caracterización de sistemas de aprendizaje automático (Machine Learning) Parte 1

Ciclo: Máster en IA y Big Data
Módulo: MP2: Sistemas de aprendizaje automático

Nil Redón Orriols


Repaso de la clase anterior

- Presentación del módulo
- Definición de IA y algoritmos de IA.
- Caracterización de los tipos de IA.
- IA Débil: Definición, características y aplicación.
- IA Fuerte: Definición, características y aplicación.
- ¿Preguntas / dudas?

Contenidos de la clase de hoy

- Tema 2 (parte 1): Sistemas de aprendizaje automático (Machine Learning).
 - Definición de Machine Learning.
 - Definición de aprendizaje supervisado y no supervisado.
 - Otras técnicas de aprendizaje automático.
 - Pasos de un proyecto de Machine Learning.
 - Tipos de problemas de Machine Learning: Clasificación, regresión, clustering...

Tipos de IA



Definición de Machine Learning

- **Inteligencia Artificial (IA):** Conjunto de capacidades cognoscitivas e intelectuales expresadas por sistemas informáticos o combinaciones de algoritmos que tienen como propósito la creación de máquinas que imitan la Inteligencia humana para realizar tareas, y que pueden mejorar a medida que recopilan información.
- **Machine Learning (Aprendizaje automático):** Subdisciplina de la inteligencia artificial que se centra en el desarrollo de algoritmos y modelos que permiten a las máquinas aprender y hacer predicciones o tomar decisiones basadas en datos.

Tipos de Machine Learning

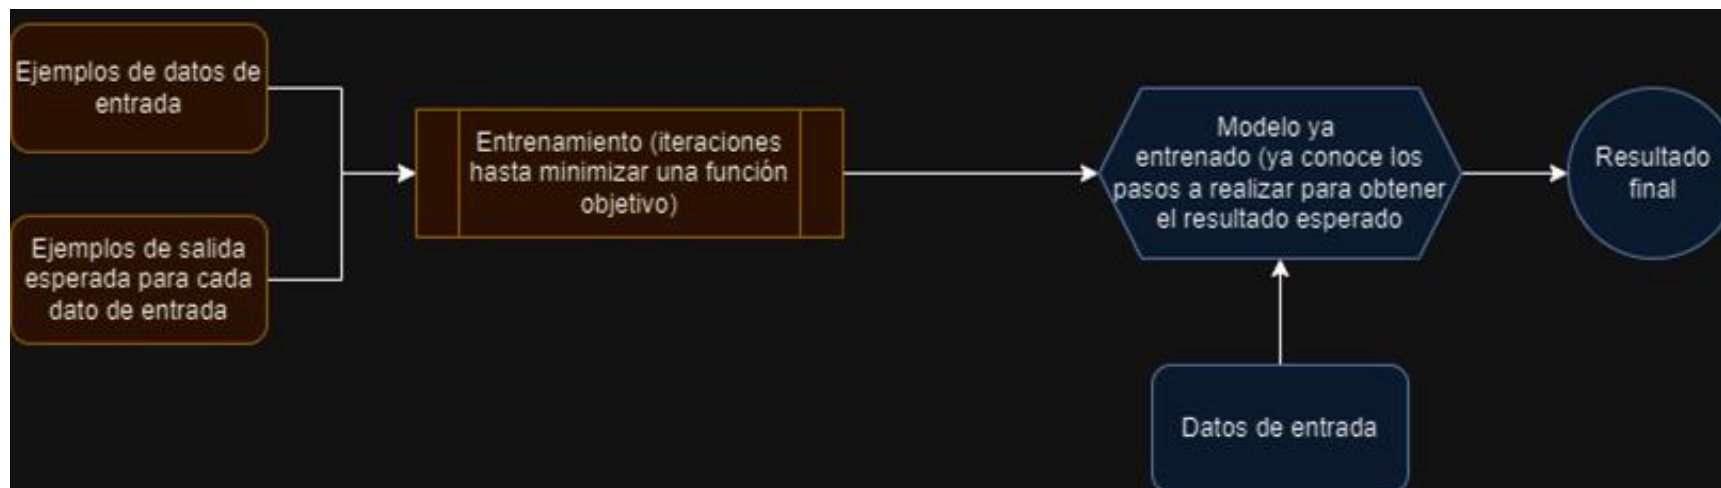
- Aprendizaje inductivo: Supervisado - No supervisado (clasificación, regresión, clustering...)
- Aprendizaje por refuerzo (reinforcement learning)
- Razonamiento basado en casos (CBR)
- Técnicas complementarias:
 - Transfer learning
 - Ensemble learning: Bagging, boosting, voting

Aprendizaje inductivo

- Idea: Partir del análisis de casos específicos para llegar a patrones generales/abstractos.
- Características principales:
 - Observación empírica de datos
 - De lo particular a la general
 - Flexibilidad para modificar con nuevas observaciones
 - Tentatividad: nuevas evidencias pueden hacer cambiar el modelo
 - Probabilístico
- Ejemplos: Algoritmos supervisados y no supervisados

Algoritmos supervisados

- Definición: El modelo se entrena utilizando un conjunto de datos etiquetados. El objetivo del modelo es aprender los patrones correspondientes para obtener el resultado esperado a partir del dato de entrada, basándose en estos ejemplos.



Algoritmos supervisados: Proceso de entrenamiento

Cuatro pasos principales:

- Selección y etiquetado de los datos.
- Selección del modelo.
- Entrenamiento y evaluación del modelo.
- Despliegue en producción y monitorización del modelo

Algoritmos supervisados: Proceso de entrenamiento

- Paso 1: Selección y etiquetado de los datos: Debemos asegurar los siguientes aspectos clave:
 - Calidad del dato
 - Equilibrio y representatividad de los datos
 - Volumen y persistencia de los datos
 - Calidad y consistencia del etiquetado
- Separaremos los datos en tres conjuntos: entrenamiento, validación y prueba.

Algoritmos supervisados: Proceso de entrenamiento

- Paso 2: Selección del modelo:
 - Principales criterios: Complejidad del problema y tipo de dato. La experiencia es clave.
 - Puede haber más de un modelo que puede dar un buen resultado. Incluso varias configuraciones de un modelo.
- Es habitual entrenar varios modelos y/o diferentes configuraciones de los mismos, y elegir el mejor resultado.

Algoritmos supervisados: Proceso de entrenamiento

- Paso 3: Entrenamiento y evaluación del modelo:
 - Definición de la función de pérdida
 - Definición de los hiperparámetros del modelo.
 - Iteraciones de entrenamiento y validación automáticas.
 - Evaluación del resultado sobre el conjunto de prueba (test set)
- El entrenamiento no es un proceso determinista, el mismo proceso puede dar resultados diferentes para un mismo modelo, con los mismos datos.
- Detalle en el Tema 3

Algoritmos supervisados: Proceso de entrenamiento

- Paso 3: Entrenamiento y evaluación del modelo:
Iteraciones de entrenamiento y validación automáticas
 - Forward pass: Obtener predicción para el conjunto de entrenamiento (training set).
 - Cálculo de la función de pérdida para medir cuánto se está equivocando el modelo.
 - Backward pass: Ajuste de los parámetros para corregir los errores (proceso de aprendizaje).
 - Cada cierto número de iteraciones, se repite el proceso con el conjunto de validación (validation set).
 - Se itera de forma automática hasta obtener un resultado suficientemente bueno (hay criterios de parada).

Algoritmos supervisados: Proceso de entrenamiento

- Paso 4: Despliegue en producción y monitorización del modelo: Puntos clave
 - Modelo listo para inferencia sobre nuevos conjuntos de datos.
 - Optimización del modelo y despliegue en entorno de producción.
 - Metodología de control de calidad y re-entrenamiento.
- MLOps: Conjunto de técnicas para controlar el ciclo de vida de los modelos.

Algoritmos supervisados: Problemas y ejemplos

- Clasificación
 - Binaria
 - Multi-clase
 - Multi-etiqueta
- Regresión
- Detección de anomalías

Algoritmos supervisados: Problemas y ejemplos

- Clasificación: Determinar a qué categoría (o clase) pertenece un dato.
 - Binaria: Dos clases posibles (A y B). Los modelos predicen la probabilidad de pertenecer a la clase A.
 - Multi-clase: N clases posibles (número finito), cada dato pertenece a una clase. Los modelos predicen la probabilidad de pertenecer a cada clase.
 - Multi-etiqueta: N clases posibles (número finito), cada dato puede pertenecer a una o más clases. Los modelos predicen la probabilidad de pertenecer a cada clase.

Algoritmos supervisados: Problemas y ejemplos

- Clasificación: Función de pérdida habitual:
 - Binaria: Log-loss o binary cross-entropy

$$\text{Log-loss} = -\frac{1}{N} \sum_{i=1}^N \left[y_i \log(p_i) + (1 - y_i) \log(1 - p_i) \right]$$

- Multi-clase: Cross- entropy

$$H(y, p) = - \sum_{i=1}^N y_i \log(p_i)$$

Algoritmos supervisados: Problemas y ejemplos

- Ejemplos reales de problemas de clasificación
 - Binaria: Detección de spam, análisis de sentimiento binario, clasificación de imágenes binaria...
 - Multi-clase: Análisis de sentimiento multi-clase, clasificación de imágenes multi-clase, reconocimiento de caracteres, clasificación de noticias, productos...
 - Multi-etiqueta: Tags sobre un contenido, detección de objetos en imágenes, diagnóstico médico...

Algoritmos supervisados: Problemas y ejemplos

- Algoritmos de clasificación:
 - Regresión logística
 - Support Vector Machines (SVM)
 - Árboles de decisión
 - Bosques aleatorios
 - K-Nearest Neighbors (KNN)
 - Redes neuronales (tema 4)
 - ...

Algoritmos supervisados: Problemas y ejemplos

- Regresión: Predecir un valor numérico continuo para cada dato.
- Problemas reales: Pricing dinámico, scoring, predicción de temperatura, predicción de ventas y stock...
- Función de pérdida:

$$L = \frac{1}{N} \sum_{i=1}^N (y_i - \hat{y}_i)^2$$

Algoritmos supervisados: Problemas y ejemplos

- Algoritmos de regresión:
 - Regresión lineal
 - Regresión multi-lineal
 - Support Vector Regressor (SVR)
 - Árboles de decisión
 - Bosques aleatorios
 - K-Nearest Neighbors (KNN)
 - Redes neuronales (tema 4)
 - ...

Algoritmos supervisados: Problemas y ejemplos

- Problema de detección de anomalías: se busca identificar outliers en un conjunto de datos
- Definición de outlier: Dato que se desvía significativamente del patrón general del resto.
- Puede ser un problema supervisado o no supervisado.
- Algoritmos supervisados: One-class SVM
- Algoritmos no supervisados: Isolation forest, K-Means, Local Outlier Factor (LOF).
- Problema real: Detección de fraude, diagnóstico médico

Algoritmos no supervisados

- En los sistemas de Machine Learning no supervisado, el modelo se entrena utilizando un conjunto de datos no etiquetados.
- Esto significa que las entradas de datos no vienen con una etiqueta o resultado esperado.
- El objetivo del modelo es identificar patrones y estructuras ocultas en los datos sin ninguna guía explícita.

Algoritmos no supervisados: Proceso de entrenamiento

Puntos clave:

- Proceso de aprendizaje en base a los datos específico de cada modelo (según el problema y el enfoque).
- Normalización previa de los datos.
- Un único conjunto de datos de entrenamiento
- Métricas de observación (insights) en vez de funciones de pérdida, al no haber etiquetas.
- Técnicas complementarias: Aprendizaje semi-supervisado, auto-supervisado y active learning.


Algoritmos no supervisados: Problemas y ejemplos

- Clustering
- Detección de anomalías (visto en el apartado anterior, ya que puede ser también supervisado)
- Reducción de dimensionalidad

Algoritmos no supervisados: Problemas y ejemplos

- Clustering: Agrupar un conjunto de datos en subconjuntos por similitud.
- La idea es extraer patrones ocultos de similitud en conjuntos de datos no etiquetados.
- No hay función de pérdida, sí puede haber índices para medir características de los clusters resultado.
- Problema real: Segmentación de usuarios/clientes, agrupación de documentos, análisis de redes sociales...

Algoritmos no supervisados: Problemas y ejemplos




Algoritmos no supervisados: Problemas y ejemplos

- Algoritmos de clustering:
 - K-Means
 - Clustering jerárquico
 - Clustering por densidad: DBSCAN...
 - Mean Shift
 - Gaussian Mixture Models (GMM)
 - ...

Algoritmos no supervisados: Problemas y ejemplos

- Reducción de dimensionalidad: Reducir la dimensión de los datos, manteniendo la mayor cantidad de información posible.
- Problema real: Algoritmo complementario a otros procesos, utilizado principalmente para compresión y visualización de datos.
- No hay función de pérdida, sí puede haber índices para medir la variabilidad capturada en el proceso.

Algoritmos no supervisados: Problemas y ejemplos



Algoritmos no supervisados: Problemas y ejemplos

- Algoritmos de reducción de dimensionalidad:
 - Embeddings (neural networks)
 - Principal Component Analysis (PCA)
 - Linear Discriminant Analysis (LDA)
 - t-SNE
 - ...

Aprendizaje basado en casos (CBR)

- Idea: Utilizar casos específicos de problemas anteriores para encontrar soluciones a problemas nuevos
- Pasos:
 - Recuperación de casos: Métrica de similitud
 - Reutilización: Adaptación al nuevo caso
 - Revisión: Prueba y error para ajustar la solución
 - Retención: Guardar el caso
- Ejemplos: Case-based-planning (CBP)

Aprendizaje por refuerzo

- Idea: Generar un entorno en que un agente reciba recompensas según sus acciones, y aprenda por prueba y error.
- Puntos clave:
 - Interacción con un entorno dinámico
 - Recompensas y penalizaciones
 - Equilibrio entre exploración y explotación
 - Aprendizaje secuencial
 - Sin datos estáticos
- Ejemplos: Q-learning, SARSA, PPO...

Técnicas complementarias: Transfer learning

- Idea: Reutilizar el conocimiento adquirido previamente por un modelo previamente entrenado para otra tarea o con otros datos.
- Puntos clave:
 - Permite acelerar el proceso de entrenamiento
 - Detección de patrones avanzada
- Ejemplos:
 - Fine-tuning de modelos LLM
 - Fine-tuning de modelos generalistas de detección de objetos o clasificación de imágenes

Técnicas complementarias: Ensemble learning

- Idea: Combinar los resultados de varios modelos para ganar robustez: se busca aprovechar las fortalezas de cada uno y mitigar sus debilidades.
- Ejemplos:
 - Bagging (Bootstrap aggregating): Entrenar múltiples modelos en subconjuntos de datos aleatorios y combinar predicciones según su confianza.
 - Boosting: Entrenar modelos secuencialmente, y cada modelo intenta corregir los errores del anterior.
 - Voting: Combina las predicciones de varios modelos mediante un sistema de votación (puede ser ponderada) y se elige la predicción resultado de la votación

Cierre

- Dossiers de actividades obligatorias y optativas en el campus: Fecha de entrega límite 20/01/2025.
- Subiré dos píldoras con información complementaria del Tema 2, una en noviembre y otra en diciembre.
- Siguiendo clase: Martes 26/11/2024, 17:30-19:00 - Tema 2 (parte 2).
- ¿Dudas/preguntas?
- Gracias por vuestra atención :)

