

Clase 3

Tema 2: Caracterización de sistemas de aprendizaje automático (Machine Learning)

Parte 2

Ciclo: Máster en IA y Big Data

Módulo: MP2: Sistemas de aprendizaje automático

Nil Redón Orriols

Repaso de la clase anterior

- Tema 2 (parte 1): Sistemas de aprendizaje automático (Machine Learning).
 - Definición de Machine Learning.
 - Definición de aprendizaje supervisado y no supervisado.
 - Otras técnicas de aprendizaje automático.
 - Pasos de un proyecto de Machine Learning.
 - Tipos de problemas de Machine Learning: Clasificación, regresión, clustering...

Contenidos de la clase de hoy

- Tema 2 (parte 2): Sistemas de aprendizaje automático (Machine Learning).
 - Algoritmos de regresión
 - Algoritmos de clasificación
 - Algoritmos de clustering
 - Árboles de decisión
 - Algoritmos de detección de anomalías
 - Algoritmos de reducción de dimensionalidad

Algoritmos supervisados: Problemas y ejemplos


- Algoritmos de regresión:
 - Regresión lineal
 - Regresión multi-lineal
 - Support Vector Regressor (SVR)
 - Árboles de decisión
 - Bosques aleatorios
 - K-Nearest Neighbors (KNN)
 - Redes neuronales (tema 4)
 - ...

Algoritmos de regresión: Regresión lineal

- La regresión lineal es el método clásico más extendido para la regresión, y sigue siendo ampliamente utilizado.
- Su objetivo es encontrar la mejor línea recta (de ahí el nombre lineal) que prediga el valor de la variable dependiente a partir de las variables independientes.
- Es un algoritmo análogo a la regresión logística, pero para regresión en vez de clasificación.

Algoritmos de regresión: Regresión lineal

- Ejemplo visual de regresión lineal



Algoritmos de regresión: Regresión lineal

- Para encontrar la recta óptima, debemos encontrar los parámetros Beta0 y Beta1 que determinan la ecuación de la misma.

$$y = \beta_0 + \beta_1 x + \epsilon$$

- Función de pérdida: MSE (Mean Squared Error)

$$L = \frac{1}{N} \sum_{i=1}^N (y_i - \hat{y}_i)^2$$

Algoritmos de regresión: Regresión lineal

- Hay una fórmula cerrada para los parámetros óptimos (sólo para el caso lineal):

$$\beta_1 = \frac{n \sum (x_i y_i) - \sum x_i \sum y_i}{n \sum (x_i^2) - (\sum x_i)^2}$$

$$\beta_0 = \bar{y} - \beta_1 \bar{x}$$

- Se puede generalizar el mismo algoritmo a polinomios de cualquier dimensión (regresión multinomial). A mayor grado, mayor riesgo de overfitting.

$$y = \beta_0 + \beta_1 x + \beta_2 x^2 + \dots + \beta_n x^n + \epsilon$$

Algoritmos de clasificación

- Clasificación: Determinar a qué categoría (o clase) pertenece un dato.
 - Binaria: Dos clases posibles (A y B). Los modelos predicen la probabilidad de pertenecer a la clase A.
 - Multi-clase: N clases posibles (número finito), cada dato pertenece a una clase. Los modelos predicen la probabilidad de pertenecer a cada clase.
 - Multi-etiqueta: N clases posibles (número finito), cada dato puede pertenecer a una o más clases. Los modelos predicen la probabilidad de pertenecer a cada clase.

Algoritmos de clasificación

- Clasificación: Función de pérdida habitual:
 - Binaria: Log-loss o binary cross-entropy

$$\text{Log-loss} = -\frac{1}{N} \sum_{i=1}^N \left[y_i \log(p_i) + (1 - y_i) \log(1 - p_i) \right]$$

- Multi-clase: Cross- entropy

$$H(y, p) = - \sum_{i=1}^N y_i \log(p_i)$$

Algoritmos de clasificación

- Ejemplos reales de problemas de clasificación
 - Binaria: Detección de spam, análisis de sentimiento binario, clasificación de imágenes binaria...
 - Multi-clase: Análisis de sentimiento multi-clase, clasificación de imágenes multi-clase, reconocimiento de caracteres, clasificación de noticias, productos...
 - Multi-etiqueta: Tags sobre un contenido, detección de objetos en imágenes, diagnóstico médico...

Algoritmos de clasificación

- Diferentes algoritmos de clasificación:
 - Regresión logística
 - Support Vector Machines (SVM)
 - Árboles de decisión
 - Bosques aleatorios
 - K-Nearest Neighbors (KNN)
 - Redes neuronales (tema 4)
 - ...


Algoritmos de clasificación

- Diferentes algoritmos de clasificación:
 - Regresión logística
 - Support Vector Machines (SVM)
 - Árboles de decisión
 - Bosques aleatorios
 - K-Nearest Neighbors (KNN)
 - Redes neuronales (tema 4)
 - ...

Algoritmos de clasificación: Regresión logística

- Regresión logística: Uno de los algoritmos más conocidos y utilizados de clasificación
- Función logística:

$$\sigma(z) = \frac{1}{1 + e^{-z}}$$



Algoritmos de clasificación: Regresión logística

- Consideramos un dato de input de dimensión n:
 $X = (X_1, X_2, \dots, X_n)$, y definimos

$$z = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_n x_n$$

- Los valores beta son los parámetros que optimizaremos en el proceso de aprendizaje automático.

Algoritmos de clasificación: Regresión logística

Pasos del proceso de entrenamiento (binario):

- Forward pass: Calculamos el valor resultante para cada uno de los datos de entrada, recordando que

$$\sigma(z) = \frac{1}{1 + e^{-z}}$$

$$z = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_n x_n$$

Algoritmos de clasificación: Regresión logística

Pasos del proceso de entrenamiento:

- Evaluación de la función de pérdida: Calculamos el error del forward pass. Recuerda que la función de pérdida es la siguiente (para el caso binario)

$$\text{Log-loss} = -\frac{1}{N} \sum_{i=1}^N \left[y_i \log(p_i) + (1 - y_i) \log(1 - p_i) \right]$$

Algoritmos de clasificación: Regresión logística

Pasos del proceso de entrenamiento:

- Backward pass: Corregimos los parámetros β_0 y β_1 para mejorar el modelo, y volvemos a iterar. Se corrigen utilizando las siguientes fórmulas (no entraremos al detalle).

$$\beta_{0_{new}} = \beta_0 - \alpha \sum \frac{1}{(1 + e^{-(\beta_0 + \beta_1 x)})^2}$$

$$\beta_{1_{new}} = \beta_1 - \alpha \sum \frac{\beta_1}{(1 + e^{-(\beta_0 + \beta_1 x)})^2}$$

Algoritmos de clasificación: Support Vector Machines

- La idea es encontrar un hiperplano que separe las diferentes clases de datos de la mejor manera posible.
- El objetivo es encontrar el hiperplano que maximiza la distancia entre él mismo y los datos más cercanos de cada clase (esta distancia es conocida como margen, y los datos más cercanos se conocen como vectores de soporte)

Algoritmos de clasificación: Support Vector Machines


- Se plantea un problema de optimización con restricciones para encontrar el hiperplano óptimo: Buscamos un hiperplano que separe lo máximo posible las clases.

$$\min_{w,b} \frac{1}{2} \|w\|^2$$

$$y_i(w \cdot x_i + b) \geq 1, \quad \forall i$$

Algoritmos de clasificación: Support Vector Machines

- Ejemplo visual de SVM



Algoritmos de clasificación: Support Vector Machines

- Se puede aplicar una función de kernel para relaciones no lineales
- Es un algoritmo más costoso computacionalmente y complejo que la regresión logística. Por lo tanto, tiene más facilidad para caer en overfitting pero más capacidad de resolución de problemas complejos con relaciones no lineales y alta dimensionalidad.

Algoritmos de clasificación: KNN

- La idea básica es que los datos cercanos entre sí tienen tendencia a pertenecer a la misma clase.
- El valor clave en este algoritmo es el parámetro K , que indica cuántos vecinos cercanos se considerarán de cara a la clasificación.
- Es habitual realizar varias iteraciones variando el valor y el orden de magnitud de K para encontrar la mejor solución.

Algoritmos de clasificación: KNN

- Algoritmo:
 - Calculamos la distancia entre cada dato y todos los demás y obtenemos los K vecinos más cercanos.
 - Se hace un recuento de las clases a las que pertenece cada vecino.
 - La clase con más votos es la que se asigna.
- Algoritmo sencillo de entender e interpretar, pero muy sensible al valor de K y poco eficiente para grandes conjuntos de datos.

Algoritmos de clasificación: Naive Bayes

- Es un algoritmo basado en el cálculo de probabilidades mediante el teorema de Bayes, que tiene la siguiente formulación:

$$P(A|B) = \frac{P(B|A) \cdot P(A)}{P(B)}$$

- Algoritmo eficiente y sencillo, aunque no suele dar un buen rendimiento con datos altamente correlacionados entre ellos.

Algoritmos de clustering: K-means

- El objetivo de este algoritmo es agrupar los datos en K clusters por similitud.
- La similitud se mide como la distancia a un punto medio entre los datos, llamado centroide.
- Este algoritmo es muy dependiente del valor de K, con lo que es habitual hacer pruebas con diferentes valores de K para obtener el mejor resultado.

Algoritmos de clustering: K-means

- Algoritmo:
 - Se seleccionan K puntos aleatorios como centroides iniciales.
 - Para cada punto de datos, se calcula la distancia a cada uno de los K centroides.
 - El punto se asigna al clúster cuyo centroide esté más cercano, y una vez asignados todos los puntos se calcula un nuevo centroide como la media de todos los puntos asignados a ese cluster.
 - Se repite el proceso de asignar puntos y recalcular centroides hasta que se alcanza la convergencia, es decir, cuando los centroides se estabilizan.

Algoritmos de clustering: K-means

- Algoritmo muy utilizado por su simplicidad, eficiencia y escalabilidad para grandes conjuntos de datos.
- Asume que los clusters son esféricos si se aplica la distancia euclidiana, y tiende a crear clusters de tamaño similar.
- Depende mucho del valor de K, es sensible a outliers y no maneja bien clusters de densidad o forma variable.

Algoritmos de clustering: Clustering jerárquico


- La idea es iniciar con un cluster para cada punto de datos, e ir agrupando los dos clusters más cercanos en cada paso hasta acabar obteniendo un único cluster final tras n iteraciones (una por cada dato).
- Es un método interpretable y que no depende de un número pre-determinado de clusters.
- Método complejo y sensible a outliers.

Algoritmos de clustering: Clustering jerárquico

- Algoritmo:
 - El proceso empieza con un cluster para cada punto y el cálculo de distancias entre clusters.
 - Los dos clusters más cercanos se fusionan en un único cluster, y se actualiza una matriz de distancias que contiene las distancias entre clusters.
 - Se repiten los pasos de fusión y actualización de los clusters hasta que se alcance el número deseado de clusters.

Algoritmos de clustering: Clustering jerárquico

- Ejemplo visual de clustering jerárquico



Algoritmos de clustering: Clustering por densidad

- Los algoritmos de clustering por densidad se basan en detectar regiones densas (con muchos datos cercanos) y definirlas como clusters.
- Hay diferentes tipos de algoritmos de densidad, uno de los más utilizados es DBSCAN y sus variantes.
- Métodos computacionalmente complejos, aunque muy útiles para clusters de densidad y forma variable.

Árboles de decisión: Para clasificación y regresión

- Un árbol de decisión es un tipo de modelo que puede ser utilizado tanto para clasificación como para regresión.
- Es un método interpretable y puede manejar bien cualquier tipo de datos.
- Tiene tendencia al overfitting y a la inestabilidad, pero hay variantes para mejorarlo (random forest, Gradient Boosting...) que son ampliamente utilizadas.

Árboles de decisión: Para clasificación y regresión

- Elementos de un árbol de decisión:
 - **Nodo raíz:** Representa la primera decisión que se toma basada en el atributo más significativo del conjunto de datos. Este nodo divide los datos en dos o más subconjuntos basados en los valores del atributo seleccionado.
 - **Nodos internos:** Los nodos internos son los puntos de decisión dentro del árbol. Cada nodo interno representa una prueba sobre un atributo, y cada rama que sale de un nodo interno representa el resultado de esa prueba.

Árboles de decisión: Para clasificación y regresión


- Elementos de un árbol de decisión:
 - **Hojas:** Las hojas son los nodos terminales del árbol de decisión. Cada hoja representa una clase (clasificación) o un valor de salida (regresión).
 - **Ramas:** Las ramas conectan los nodos del árbol y representan el resultado de una prueba en un nodo.
- La idea es iterar con diferentes características y valores en los nodos hasta obtener el árbol de decisión óptimo sobre los datos de entrenamiento.

Árboles de decisión: Para clasificación y regresión

- Algoritmo:
 - **Selección de atributos:** Se eligen los atributos o características que serán útiles para tomar decisiones.
 - **Construcción del árbol:** Se elige el atributo más significativo para ser el nodo raíz. Se dividen los datos en subconjuntos basados en los valores del atributo seleccionado, se selecciona el siguiente atributo más significativo y se repite el proceso de división. Así iterativamente hasta que cada nodo hoja contenga datos que sean todos de una misma categoría (clasificación) o se cumpla una condición de parada (regresión)
 - **Poda del árbol:** Eliminar ramas en caso de overfitting.

Árboles de decisión: Para clasificación y regresión

- Ejemplo visual de árbol de decisión:



Detección de anomalías: Isolation forest

- La idea básica es que si conseguimos aislar un dato en base a un número suficientemente bajo de iteraciones de árboles de decisión, este será un dato anómalo.
- Método computacionalmente muy eficiente, que escala bien a conjuntos con grandes volúmenes de datos, robusto e interpretable
- Depende de la elección de parámetros como el número de árboles y la profundidad máxima de los árboles.

Detección de anomalías: Isolation forest

- Algoritmo:
 - **Construcción de árboles:** Se construyen múltiples árboles de manera aleatoria, seleccionando aleatoriamente una característica y un valor de división dentro del rango de esa característica. Este proceso se repite hasta que cada punto de datos esté aislado en una hoja del árbol o hasta que se alcance una profundidad máxima predefinida.
 - **Profundidad del camino:** Para cada punto de datos, se calcula la profundidad del camino, que es el número de divisiones necesarias para aislar ese punto en un árbol. Se promedia la profundidad del camino a través de todos los árboles del bosque.
 - Puntuación de anomalía: La puntuación de anomalía se calcula utilizando la profundidad del camino promedio.

Detección de anomalías: Isolation forest

- Algoritmo:
 - **Puntuación de anomalía:** Los puntos con una profundidad de camino promedio baja reciben una puntuación de anomalía alta, indicando que son más probables de ser anomalías, y viceversa.
 - **Umbral de anomalía y detección:** Se establece un umbral de puntuación de anomalía, y los puntos con puntuaciones de anomalía por encima del umbral se consideran anomalías.

Reducción de dimensionalidad: PCA

- PCA es un método estadístico que transforma los datos a un conjunto de menor dimensión manteniendo la mayor información posible.
- El conjunto de valores final, llamado componentes principales, no tienen correlación entre ellos.
- Método simple y eficiente, aunque no captura correlaciones no lineales.

Reducción de dimensionalidad: PCA

- Algoritmo:
 - **Estandarización de los datos:** Cada variable debe tener una media de cero y una desviación estándar de uno.
 - **Cálculo de la matriz de covarianza, vectores propios y valores propios.**
 - **Selección de componentes principales:** Se seleccionan los componentes principales que explican la mayor parte de la variabilidad en los datos (por ejemplo, el 95%).
 - **Transformación de los datos:** Los datos originales se transforman a este nuevo espacio de componentes principales, reduciendo así la dimensionalidad mientras se retiene la mayor variabilidad posible.

Cierre

- Dossiers de actividades obligatorias y optativas en el campus: Fecha de entrega límite 20/01/2025.
- Subiré una píldora sobre Reinforcement learning.
- Subiré una segunda píldora del Tema 2 durante el mes de diciembre, ¡estad atentos al foro!
- Siguiendo clase: 11/02, 17:30-19:00 - Tema 3 (parte 1).
- ¿Dudas/preguntas?
- Gracias por vuestra atención :)

